Operaciones Básicas en Machine Learning

Medición de errores, tasas de aprendizaje y la técnica de Broadcasting

Este documento constituye el puente fundamental entre la estructura de datos matricial y la dinámica del aprendizaje automático. Aquí aprenderás a transformar simples arreglos numéricos en mecanismos de retroalimentación inteligente. El proceso se centra en utilizar la aritmética vectorial para cuantificar discrepancias (el error) y modular correcciones precisas (la tasa de aprendizaje). El objetivo de este texto es dominar operaciones esenciales como la resta, el escalamiento y el *Broadcasting*, herramientas potentes que permiten medir el desempeño de un modelo y manipular grandes volúmenes de información de manera eficiente para el entrenamiento de algoritmos.

1. La Resta de Vectores: El Mapa del Error

Todo sistema de aprendizaje supervisado funciona bajo un ciclo constante de comparación. No basta con saber que el modelo se equivocó; necesitamos saber hacia dónde y con qué magnitud.

En nuestro código, definimos dos vectores clave: $calificaciones_reales$ (la verdad) y $prediccion_modelo$ (la estimación).

Concepto Clave: El Gradiente de Error

Al ejecutar la línea $error = calificaciones_reales - prediccion_modelo$, estamos realizando una resta elemento a elemento. El vector resultante $[1, -2]$ no son solo números, son instrucciones direccionales:

- **El $+1$ (Ciencia Ficción):** Le dice al modelo "te quedaste corto, debes aumentar tu valoración en esta dirección".
- El -2 (Comedia): Le dice al modelo "te excediste, debes disminuir tu valoración drásticamente aquí".
  Sin esta operación de resta, el modelo sería ciego; con ella, tiene una brújula que le indica hacia dónde moverse.

2. Multiplicación por Escalar: Controlando la Estabilidad

Una vez que tenemos el vector error, la intuición nos diría que lo sumemos directamente para corregir el modelo. ¡Pero esto es peligroso! Si corregimos el 100% del error de golpe, el modelo oscilaría violentamente y nunca se estabilizaría.

Aquí entra la variable $porcentaje_ajuste$ (en la teoría conocida como Learning Rate o Tasa de Aprendizaje).

Concepto Clave: La Tasa de Aprendizaje

En el código usamos $ajuste = error * porcentaje_ajuste$ (donde el escalar es 0.1).

- **Matemáticamente:** Estamos escalando la longitud del vector de error, haciéndolo más pequeño sin cambiar su dirección.
- **En ML:** Estamos decidiendo dar un "paso pequeño y seguro" hacia la solución. En lugar de cambiar los parámetros en 2 unidades completas (para Comedia), los cambiamos solo en 0.2. Esto permite que el modelo aprenda de muchos ejemplos gradualmente sin romperse por un solo dato atípico.

3. Suma de Matrices: Agregación de Datos Históricos

A menudo necesitamos consolidar información. En el ejemplo del e-commerce, tenemos $ventas_enero$ y $ventas_febrero$. La operación $ventas_enero + ventas_febrero$ representa la acumulación de evidencia.

Concepto Clave: Correspondencia Posicional

Para que esta suma tenga sentido en un contexto de datos, la estructura debe ser rígida: la fila 0 siempre debe ser el "Producto A" y la columna 0 la "Tienda 1" en ambas matrices. La suma matricial preserva esta estructura, permitiéndonos generar métricas acumuladas (como ventas trimestrales o anuales) instantáneamente, sin necesidad de bucles de programación lentos.

4. Broadcasting: Eficiencia y Ajustes Globales

En el código, cuando sumamos $ventas_enero + bonificaciones$, estamos haciendo algo que parece matemáticamente imposible: sumar una matriz $(2, 3)$ con un vector $(3,)$.

NumPy resuelve esto mediante Broadcasting.

Concepto Clave: Expansión Virtual

El intérprete de Python analiza las dimensiones:

1. Ve que la matriz tiene 3 columnas.
2. Ve que el vector bonificaciones tiene 3 elementos.
3. La Magia: NumPy "clona" virtualmente el vector $[10,\ 15,\ 5]$ y lo aplica a cada fila de la matriz de ventas.
   Esto es fundamental en Machine Learning para aplicar sesgos (biases). Por ejemplo, si descubres que todas las tiendas vendieron un poco más por ser temporada navideña, puedes sumar un vector de "efecto navidad" a toda tu base de datos de una sola vez, ahorrando memoria y tiempo de procesamiento.

5. Resumen y Desafío

Hoy has dominado las operaciones aritméticas básicas con matrices aplicadas a la IA. Ahora sabes:

- Usar la **resta** (reales - prediccion) para crear un mapa direccional del error.
- Aplicar la **multiplicación por escalar** (error * rate) para controlar la estabilidad del aprendizaje.
- Y entiendes el **broadcasting**, que te permite aplicar ajustes globales (como el vector bonificaciones) a grandes matrices de datos.

Tu desafío es:

Imagina que tienes una matriz puntos de forma $(4, 3)$ que representa las coordenadas (x, y, z) de 4 objetos en un videojuego.

Define un vector_desplazamiento (ej. $[2,\ -1,\ 5]$). Usa broadcasting para sumar este vector a tu matriz y "mover" todos los objetos al mismo tiempo.

¡Pública en los comentarios tu matriz original, tu vector y la matriz resultante $nuevos_puntos$!